

Étape 1 – Découverte des sources de données

1. Contexte et périmètre

Le projet consiste à développer un **bot de trading crypto** basé sur un modèle de Machine Learning.

L'objectif de cette première étape est de :

- Identifier les **sources de données disponibles**,
 - Comprendre leur **périmètre et leurs limites**,
 - Fournir des **exemples de données collectées**,
 - Justifier pourquoi nous utilisons des **APIs** plutôt que du **scraping**.
-

2. Sources de données étudiées

2.1 Binance API

- **Type** : REST + Websocket
- **Accès** : Gratuit (avec authentification pour certaines routes)
- **Avantages** : Données complètes, haute fréquence, temps réel.
- **Données disponibles** : prix spot, historiques OHLCV, carnet d'ordres, volumes.
- **Exemple (prix spot BTC/USDT)** :

```
{  
  "symbol": "BTCUSDT",  
  "price": "67895.45"  
}
```

- **Exemple (bougies OHLCV)** :

```
[  
  1727800000, // timestamp
```

```
"67800.12", // open
"68010.45", // high
"67550.00", // low
"67895.45", // close
"1023.45"   // volume
]
```

2.2 CoinGecko API

- **Type** : REST
- **Accès** : 100% gratuit, pas besoin de clé API
- **Avantages** : Simplicité, données historiques longues, plus de 12 000 cryptos.
- **Limites** : Rate limit de 50 appels/min.
- **Exemple (prix actuel BTC/USDT)** :

```
{
  "bitcoin": {
    "usd": 67895,
    "eur": 64321
  }
}
```

2.3 CryptoCompare API

- **Type** : REST
- **Accès** : Gratuit limité, payant pour plus de granularité
- **Avantages** : Agrégation multi-exchanges, données sentiment/news.
- **Exemple (historique 1h BTC/USDT)** :

```
{
  "Time": 1727800000,
  "Open": 67800.12,
  "High": 68010.45,
  "Low": 67550.00,
```

```
"Close": 67895.45,  
"VolumeFrom": 1023.45,  
"VolumeTo": 69451234.56  
}
```

3. API vs Scraping

Dans le domaine de la crypto :

-  Les **APIs sont la norme** : elles donnent directement accès aux données de marché en JSON, en temps réel et avec historique.
-  Le **scraping est inutile** dans la majorité des cas, car les sites web des exchanges affichent exactement les données provenant des APIs.
-  Le scraping devient intéressant uniquement pour des **données contextuelles externes** (ex : news, tweets, tendances Google, Reddit).

Conclusion : pour ce projet, les **APIs open source suffisent largement** à couvrir les besoins.

4. Pré-processing prévu

Avant utilisation dans le modèle ML :

- Conversion des données JSON en **DataFrame pandas**.
- Normalisation des timestamps en format standard (`YYYY-MM-DD HH:MM:SS`).
- Uniformisation des symboles de marché (ex : `BTCUSDT` vs `BTC/USDT`).
- Suppression des doublons et gestion des valeurs manquantes.

5. Livrables produits (Étape 1)

-  **Rapport explicatif** (ce document).
-  **Exemples de données JSON collectées** (prix spot et historique).

6. Conclusion

Les sources **Binance**, **CoinGecko** et **CryptoCompare** seront utilisées pour la suite du projet :

- **Binance** → flux en temps réel + historiques haute fréquence.
- **CoinGecko** → vision macro + simplicité d'utilisation.
- **CryptoCompare** → complément pour agrégations et éventuelles données sentiment.

👉 Les données sont **suffisamment accessibles via APIs**, sans nécessité de scraping.

👉 Ces bases permettront de construire l'architecture de stockage à l'**étape 2**.